

COMPFEST 18 DSA — FINAL PROJECT

Audit Project

OCR Document Information Extraction

Ringkasan faktual artefak, eksperimen, metrik, dan gap bukti untuk membangun storyline presentasi.

Prinsip audit

Tidak ada eksperimen diasumsikan. Klaim hanya dibuat bila didukung notebook, source code, dokumentasi, output tersimpan, atau artefak visual yang ada di repository.

1. Executive Summary

- Dataset lokal berisi **732 image JPEG/RGB**; **632** memiliki ground truth dan **100** belum berlabel. Target extraction: `name`, `birth_date`, `address`.
- EDA menemukan heterogenitas resolusi/orientasi dan variasi kualitas: **357/732** image memiliki minimal satu quality flag.
- Baseline terukur membandingkan Tesseract, EasyOCR, dan TrOCR-small-printed pada held-out Malaysian test set **n=11**. EasyOCR terbaik untuk birth date dan address menurut CER/WER.
- Perbaikan terukur adalah **EasyOCR + Malaysian structured parser**: Name CER turun 85.2% → 52.8%; address exact naik 0% → 9.1%, walau CER/WER address memburuk.
- P4 preprocessing terbukti dijalankan pada 732 image. P5 memuat kandidat preprocessing serta visual QA, tetapi tidak menyediakan log run atau CER/WER; karena itu tidak boleh diklaim sebagai peningkatan OCR.
- Tidak ditemukan implementasi atau report **PaddleOCR / PaddleOCR Small v6**.

Sumber: `eda_ocr.ipynb`; `p4_preprocessing_baseline.ipynb`; `BASELINE.md`; `reports/malaysia_summary.md`.

2. Project Artefact Inventory

Artefak	Tahap	Tujuan	Temuan penting
<code>eda_ocr.ipynb</code>	EDA	Audit label dan image	Hasil data/image quality paling lengkap.
<code>fix_ground_truth.ipynb</code>	Data cleaning	Standardisasi parsing CSV	632/632 row diparsing; output CSV tidak dikomit.
<code>p4_preprocessing_baseline.ipynb</code>	Preprocessing	Validation → resize → contrast normalization	732/732 image selesai diproses dan diverifikasi.
<code>p5_preprocessing_candidates.ipynb</code> + <code>p5_review/</code>	Kandidat preprocessing	Eksplorasi image enhancement dan document geometry	Kode dan visual tersedia; log/metrik tidak tersedia.
<code>BASELINE.md</code> ; <code>reports/malaysia_summary.md</code>	OCR evaluation	Dokumentasi hasil baseline	Satu-satunya sumber agregat CER/WER.
<code>src/ocr_baseline/</code>	Inference & extraction	Engine, parser, scoring	EasyOCR structured pipeline telah diimplementasikan.
<code>tests/</code>	Unit test	Parser dan metric logic	Test sintetis; bukan evidence hasil OCR image riil.

3. EDA Findings

Dataset overview

- Ground truth memiliki 4 kolom: `filename`, `name`, `birth_date`, `address`; 632 filename unik.
- Address tersedia pada 112 row dan kosong pada 520 row. Subset Malaysian dipilih dari address yang tidak kosong.
- Terdapat 20 birth date berupa tahun saja (1983), tidak memenuhi `YYYY-MM-DD`.
- Terdapat 152 identitas unik menurut kombinasi `name`, `date`, `address`; duplicate identity mewakili variasi image kartu/identitas yang sama, bukan byte-identical image.

Karakteristik visual dan implikasi

Temuan	Dampak potensial	Respons yang didukung artefak
Resolusi 197×124 hingga 4608×3840; median 2160×3840	Legibilitas teks kecil tidak seragam	P4 resize cap 1800; P5.1 mendesain upscale untuk image very-low-res.
57.65% portrait, 42.08% landscape, 1 square	Fixed crop rentan terhadap framing/layout	P5.7 ROI crop dan P5.8 perspective correction sebagai kandidat.
74 image blur berat; 74 high-noise; 74 background proxy tinggi	Karakter dapat kabur atau noise terbaca sebagai text	P5 mencakup denoise, sharpening, thresholding; belum ada evaluasi OCR.
357/732 memiliki ≥1 quality flag	Data tidak homogen	P4 membuat preprocessing baseline dan log per image.
Semua image JPEG/RGB; corrupt 0; duplicate byte-identik 0	Tidak ada masalah format file	P4 menyimpan output RGB JPEG konsisten.

Interpretasi terbatas: metric background pada EDA sendiri dinyatakan eksperimental; area sudut tidak selalu background sebenarnya.

Sumber: eda_ocr.ipynb.

4. Preprocessing Experiment Summary

ID	Pipeline / konfigurasi	Bukti output	OCR evaluation	Insight audit
P4.1	Load validation RGB	732/732 readable, 3 channel	Not Available	Input dapat diproses tanpa file corrupt.
P4.2	Resize proporsional; long-side cap 1800; no upscale; low-res <300	732/732; 425 downscaled; 307 unchanged; 10 very-low-res	Not Available	Menyeragamkan batas ukuran tanpa menghilangkan low-res flag.
P4.3	LAB-L percentile stretch 1–99	732/732; mean brightness 118.38 → 132.34	Not Available	Normalisasi selesai, tetapi belum tersambung ke baseline OCR.
P5.1	Upscale Lanczos/Cubic untuk 10 very-low-res; target 1800	Visual before/after tersedia	Not Available	Tidak ada log jumlah sukses atau CER/WER.
P5.2	Grayscale	Visual tersedia	Not Available	Kandidat standalone, bukan pipeline final.
P5.3	CLAHE LAB-L: clip 1/2/3/4 × tile 8×8/16×16	Visual tersedia	Not Available	Seleksi quality proxy dirancang, tetapi hasilnya tidak tersimpan.
P5.4–P5.6	NLMeans/Gaussian/median; unsharp/Laplacian; Otsu/adaptive/Sauvola	Visual tersedia	Not Available	Tidak boleh diklaim meningkatkan OCR.
P5.7–P5.8	Canny/contour ROI; perspective correction jika skew ≥3%	Visual tersedia	Not Available	Detection/rectification rate tidak tersedia.

Sumber: [p4_preprocessing_baseline.ipynb](#); [p5_preprocessing_candidates.ipynb](#); [p5_review/](#).

5. OCR Model Comparison

Test set: Malaysian identity-disjoint, n=11. CER/WER lebih rendah berarti lebih baik.

Model / konfigurasi	Name CER	Name WER	Birth CER	Birth WER	Address CER	Address WER
Tesseract baseline	74.0%	96.2%	67.3%	72.7%	91.2%	148.1%
EasyOCR baseline	84.9%*	85.6%	22.7%	24.2%	62.4%	78.4%
TrOCR-small-printed baseline	91.3%	100.0%	90.9%	90.9%	98.5%	100.0%
EasyOCR malaysia-structured	52.8%	67.4%	N/A	N/A	68.0%	81.4%

Parser	Name exact	Birth exact	Address exact	Kesimpulan
EasyOCR fixed-crop baseline	9.1%	63.6%	0.0%	OCR text saja belum cukup untuk exact field extraction.
EasyOCR Malaysian structured	9.1%	63.6%	9.1%	Name CER membaik; address exact naik tetapi error rata-rata tidak membaik.

* Konflik dokumentasi: generic table menulis EasyOCR Name CER 84.9%, sedangkan parser-comparison menulis 85.2% untuk fixed-crop baseline yang diklaim memakai konfigurasi/test set sama. Raw report tidak tersedia untuk menyelesaikannya.

Sumber: [BASELINE.md](#); [reports/malaysia_summary.md](#); [src/ocr_baseline/engines.py](#); [src/ocr_baseline/evaluate.py](#).

6. Error Analysis

Raw prediction JSON tidak dikomit karena PII. Maka audit tidak dapat memberikan contoh gagal per filename; tabel berikut hanya memuat pola yang didukung metrik, source code, atau test sintetis.

Error/pattern	Field	Evidence	Dampak / akar masalah
Birth-date extraction belum penuh	Birth date	EasyOCR exact 63.6%; Tesseract 27.3%; TrOCR 9.1%	Parser MyKad memakai glyph correction dan validasi kalender.
Address baseline tidak exact	Address	0/11 exact pada semua model baseline	Root cause spesifik tidak dapat dipastikan tanpa raw prediction.
Structured address trade-off	Address	Exact 0→9.1%, namun CER/WER naik	Spatial candidate selection belum stabil secara rata-rata.
Card metadata contamination	Address	Kode menghapus WARGANEGARA, ISLAM, LELAKI, dll.	Bukti mitigasi kode, bukan frekuensi failure riil.
Digit-letter OCR confusion	MyKad/birth date	Parser menangani O→0, I/L/T→1, S→5; unit test sintetis	Membantu candidate yang sudah memiliki pola MyKad.

7. Chronological Project Story

Phase 1 — Data understanding

Problem dipersempit menjadi extraction tiga field. Dataset berisi labeled image dan unlabeled image; Malaysian subset dipilih melalui address annotation.

Phase 2 — EDA dan ground-truth cleaning

CSV parsing diperbaiki; EDA menunjukkan ketidakhomogenan visual, repeated identities, dan label quality issues.

Phase 3 — Preprocessing baseline

P4 membangun pipeline image-only reproducible: validation, resize, dan LAB contrast normalization. Tahap ini membuktikan kesiapan input, bukan peningkatan OCR.

Phase 4 — OCR baseline

Tesseract, EasyOCR, dan TrOCR dibandingkan zero-shot. EasyOCR dipilih sebagai engine lanjutan karena menyediakan detections, boxes, dan confidence.

Phase 5 — Structure-aware extraction

EasyOCR boxes digunakan untuk line grouping, MyKad anchor detection, candidate association, dan metadata removal. Ini adalah perubahan pipeline yang memiliki hasil terukur.

Phase 6 — Candidate image improvements

P5 menambah kandidat enhancement dan document geometry. Bukti saat ini hanya visual QA; hubungan sebab-akibat menuju angka OCR belum tersedia.

8. Implementation Status

Status	Komponen
Implemented	Data parsing; identity-disjoint split; Tesseract/EasyOCR/TrOCR; CER/WER; MyKad parser; EasyOCR boxes/confidence; structured name/address extraction; normalization.
Executed offline but not integrated	P4 resize + contrast normalization pada 732 image.
Candidate code / insufficient evidence	P5 upscale, grayscale, CLAHE, denoise, sharpen, threshold, ROI crop, perspective correction.
Not evidenced	Preprocessing → OCR experiment matrix; raw error samples; PaddleOCR; final selected end-to-end preprocessing pipeline.

9. Recommended 11-Slide PPT Storyline

Slide	Judul	Pesan utama	Evidence / visual
1	Problem & scope	Extract 3 fields dari identity document.	632 labels, 732 image, scope Malaysian.
2	Data reality	Data tidak langsung siap digunakan.	CSV quoting; 520 blank address; 20 non-standard date.
3	Dataset landscape	Resolusi dan orientasi heterogen.	Histogram resolusi/orientasi.
4	Image quality risks	Quality variation menciptakan risiko OCR.	357/732 quality flag summary.
5	Preprocessing baseline	Bangun input pipeline reproducible.	P4 before/after dan 732/732 success.
6	OCR baseline	Tiga pretrained engine diuji.	Heatmap CER/WER.
7	What baseline taught us	EasyOCR kuat untuk date/address, exact extraction tetap lemah.	Exact + regex metrics.
8	From text to structure	Transcript saja tidak cukup; geometry diperlukan.	Boxes → lines → MyKad anchor → candidates.
9	Measured improvement	Structured parser meningkatkan Name CER dan Address exact.	Before/after metric cards.
10	Candidate image improvements	P5 adalah eksplorasi visual, belum hasil OCR final.	P5 montage dengan label "no CER/WER yet".
11	Current state & next evidence	Fokus pada benchmark preprocessing × OCR.	Status roadmap dan gap bukti.

10. Critical Missing Information / Gaps

1. Raw OCR report/prediction JSON tidak tersedia, sehingga failure case riil tidak dapat diaudit.
 2. P4/P5 output image serta CSV logs tidak dikomit; artefak yang tersedia tidak cukup untuk mereproduksi metrik P5.
 3. Tidak ada CER/WER untuk P4 maupun kandidat P5.
 4. Tidak ada benchmark yang menghubungkan preprocessing configuration, OCR model, dan field-level metrics.
 5. Tidak ada evidence PaddleOCR Small v6.
 6. Konfigurasi historical fixed-crop versus full-card untuk report baseline tidak dapat diverifikasi tuntas; source saat ini menggunakan full OCR text untuk name/birth-date dan crop untuk address.
- Recommended next evidence:** rerun P4 → rerun P5 dengan log permanen → benchmark raw/P4/P5 terpilih pada test split yang sama → simpan report teragregasi dan contoh failure anonymized.

Source Artefacts

eda_ocr.ipynb · fix_ground_truth.ipynb · p4_preprocessing_baseline.ipynb · p5_preprocessing_candidates.ipynb · p5_review/ · BASELINE.md · reports/malaysia_summary.md · src/ocr_baseline/engines.py · src/ocr_baseline/evaluate.py · src/ocr_baseline/malaysian_pipeline.py · tests/